

# Analisis Komparatif Performa Arsitektur CNN From Scratch dan Transfer Learning pada Klasifikasi Citra Digital

Tugas Individu Pembelajaran Mesin 2

Gusti Ahmad Muttahid Bilhaq  
Informatics Engineering  
Universitas Darussalam Gontor  
Ponorogo, Indonesia

gustiahmadmuttahidbilhaq73@student.cs.unida.gontor.ac.id

**Abstract**—Klasifikasi citra biner merupakan salah satu permasalahan fundamental dalam bidang visi komputer. Penelitian ini bertujuan untuk membandingkan secara objektif dua pendekatan utama dalam pembelajaran mendalam (Deep Learning), yaitu pembangunan arsitektur Convolutional Neural Network (CNN) dari dasar (From Scratch) dan pemanfaatan metode Transfer Learning menggunakan pretrained model MobileNetV2 dengan strategi Feature Extraction. Eksperimen dilakukan menggunakan dua dataset berbeda, yakni CIFAR-10 sub-kelas kucing dan anjing untuk model dari dasar, serta dataset Microsoft Cats vs Dogs dari Kaggle untuk model Transfer Learning. Pengujian dilakukan dengan pembagian data yang presisi, yaitu 70% training, 15

**Index Terms**—CNN From Scratch, Transfer Learning, MobileNetV2, Klasifikasi Citra, CIFAR-10, Cats vs Dogs.

## I. DESKRIPSI DATASET

Eksperimen ini memanfaatkan dua jenis dataset citra digital yang berbeda untuk mengakomodasi karakteristik dari masing-masing metode yang diuji:

### A. Dataset Skenario 1 (CNN From Scratch)

Dataset yang digunakan dikstraksi dari dataset publik CIFAR-10. Proses penyaringan dilakukan untuk mengambil sub-kelas spesifik, yaitu kelas kucing (*Cat* - indeks 3) dan kelas anjing (*Dog* - indeks 5). Dari ekstraksi ini, ditemukan total 10.000 gambar pada *train set* asli dan 2.000 gambar pada *test set* asli. Seluruh gambar memiliki resolusi rendah sebesar  $32 \times 32$  piksel dengan format warna RGB (3 *channels*).

### B. Dataset Skenario 2 (Transfer Learning)

Dataset yang digunakan adalah *Microsoft Cats vs Dogs* yang diunduh secara resmi melalui *KaggleHub*. Dataset ini berisikan citra resolusi penuh dengan variasi ukuran piksel yang beragam. Untuk kebutuhan komputasi yang efisien namun tetap representatif, diambil sampel acak terstratifikasi (*stratified sampling*) sebanyak 4.000 gambar dari total keseluruhan populasi data guna menjaga keseimbangan distribusi kelas target.

Sesuai dengan ketentuan eksperimen, kedua dataset dibagi ulang secara presisi ke dalam tiga subset dengan proporsi: 70%

untuk data pelatihan (*training*), 15% untuk data validasi (*validation*), dan 15% untuk data pengujian (*testing*). Distribusi kuantitatif pembagian data akhir disajikan pada Tabel I.

TABLE I  
DISTRIBUSI PEMBAGIAN DATASET EKSPERIMEN

| Subset Data     | Eksperimen 1 (CIFAR-10) | Eksperimen 2 (Kaggle) |
|-----------------|-------------------------|-----------------------|
| Pelatihan (70%) | 8.400 sampel            | 2.800 sampel          |
| Validasi (15%)  | 1.800 sampel            | 600 sampel            |
| Pengujian (15%) | 1.800 sampel            | 600 sampel            |
| Total           | 12.000 sampel           | 4.000 sampel          |

## II. PREPROCESSING DATA

Tahapan pra-pengolahan data (*preprocessing*) dirancang secara saksama untuk mengoptimalkan proses pelatihan dan mencegah terjadinya *overfitting*.

### A. Skenario 1 (CNN From Scratch)

Pada tahap penyiapan data latihan, diterapkan teknik augmentasi data berupa *Random Crop* berukuran 32 piksel dengan *padding* sebesar 4 piksel, serta *Random Horizontal Flip*. Setelah itu, data dikonversi menjadi representasi tensor dan dilakukan normalisasi menggunakan nilai rata-rata (*mean*) 0.5 dan deviasi standar (*std*) 0.5 untuk menggeser rentang nilai piksel menjadi  $[-1, 1]$ . Untuk data validasi dan pengujian, proses augmentasi ditiadakan, dan hanya diaplikasikan transformasi tensor serta normalisasi. Target label dikonversi menjadi biner, di mana kelas kucing direpresentasikan dengan nilai 0 dan kelas anjing dengan nilai 1.

### B. Skenario 2 (Transfer Learning)

Transformasi citra disesuaikan secara ketat dengan standar arsitektur *pretrained model* MobileNetV2. Citra masukan yang memiliki ukuran beragam diubah dimensinya (*Resize*) menjadi resolusi  $224 \times 224$  piksel. Pada data latihan, diaplikasikan pula teknik augmentasi *Random Horizontal Flip*. Normalisasi

data dilakukan menggunakan parameter bobot bawaan ImageNet, yaitu nilai  $mean = [0.485, 0.456, 0.406]$  dan  $std = [0.229, 0.224, 0.225]$ .




Fig. 1. Sampel visualisasi citra biner hasil preprocessing pada dataset CIFAR-10.

### III. IMPLEMENTASI CNN FROM SCRATCH

Arsitektur *SimpleCNN* dibangun dari dasar dengan memanfaatkan 3 buah blok konvolusi utama sebagai pengekstraksi fitur bentuk tingkat rendah hingga tingkat tinggi. Desain arsitektur ini dipilih secara logis untuk menangani kompleksitas citra berdimensi rendah tanpa memicu *overfitting*. Detail parameter fungsional dari arsitektur ini meliputi:

- **Blok Konvolusi 1:** Terdiri atas *Convolutional Layer* dengan 3 *input channels* dan 32 *output channels*, ukuran filter (kernel) sebesar  $3 \times 3$ , dan *padding* 1. Lapisan ini dilengkapi dengan *Batch Normalization* untuk mempercepat konvergensi, fungsi aktivasi *ReLU*, dan *Max Pooling*  $2 \times 2$  dengan *stride* 2.
- **Blok Konvolusi 2:** Menerima 32 *channels* dan menghasilkan 64 *output channels* dengan konfigurasi kernel, *Batch Normalization*, *ReLU*, dan *Max Pooling* yang sama seperti blok pertama.
- **Blok Konvolusi 3:** Menerima 64 *channels* dan menghasilkan 128 *output channels* dengan spesifikasi kernel dan fungsionalitas yang identik dengan blok sebelumnya.
- **Lapisan Regularisasi & Klasifikasi:** Fitur keluaran tensor 3D dari blok konvolusi terakhir ( $128 \times 4 \times 4$ ) diratakan (*Flattening*) menjadi tensor 1D berdimensi 2.048. Fitur tersebut kemudian dihubungkan ke *Fully Connected Layer* pertama ('nn.Linear') dengan 256 neuron, dilapisi fungsi aktivasi *ReLU*, serta dikombinasikan dengan *Dropout* sebesar 0.4 untuk memutus dependensi antar-neuron secara acak. Lapisan *Output* akhir memetakan 256 fitur ke dalam 2 logits kelas keluaran.

Model ini dioptimasi menggunakan algoritma *Adam Optimizer* dengan nilai tingkat pembelajaran (*learning rate*) sebesar 0.001, fungsi kerugian *Cross Entropy Loss*, serta penambahan parameter *weight decay* sebesar  $1e - 4$  sebagai bentuk regularisasi L2 tambahan.

### IV. IMPLEMENTASI TRANSFER LEARNING

Skenario eksperimen kedua mengimplementasikan metode *Transfer Learning* dengan memanfaatkan arsitektur jaringan *MobileNetV2* yang telah dilatih menggunakan miliaran data gambar pada ImageNet. Alasan mendasar pemilihan *MobileNetV2* adalah efisiensi komputasinya yang sangat tinggi

berkat penggunaan struktur *inverted residual blocks* dan *depth-wise separable convolutions*, sehingga sangat ideal untuk dijalankan di lingkungan *resource-constrained* seperti Kaggle dengan performa akurasi yang tetap superior.

Strategi *Transfer Learning* yang diterapkan dalam penelitian ini adalah **Feature Extraction**. Implementasi dilakukan melalui tahapan operasional sebagai berikut:

- 1) Memuat arsitektur dasar dan bobot parameter asli dari *MobileNetV2*.
- 2) Membekukan seluruh parameter pada seluruh lapisan dasar arsitektur model dengan mengatur properti *requires\_grad = False*. Langkah ini mengunci nilai ekstraktor fitur bawaan ImageNet agar tidak berubah selama proses pelatihan ulang.
- 3) Melakukan modifikasi pada lapisan klasifikasi terakhir (*Classifier Layer*). Lapisan linear pembawa fitur (*in\_features = 1280*) diarahkan ulang menuju lapisan struktural baru ('nn.Linear') dengan dimensi keluaran disesuaikan menjadi 2 kelas target (kucing dan anjing).

Optimasi dilakukan menggunakan fungsi kerugian *Cross Entropy Loss* dan pengoptimal *Adam* dengan *learning rate* 0.001. Parameter yang didaftarkan ke dalam pengoptimal didefinisikan secara eksklusif hanya untuk bagian *classifier* baru, sehingga komputasi *backpropagation* berjalan sangat efisien.

### V. HASIL EKSPERIMEN DAN PERBANDINGAN MODEL

Proses evaluasi akhir dilakukan secara objektif dengan menguji kedua model terlatih pada masing-masing data pengujian (*Test Set*) yang terisolasi dari proses pelatihan.

#### A. Analisis Kuantitatif

Berdasarkan data yang dihimpun pada saat proses eksekusi, model CNN From Scratch memerlukan waktu latihan selama 38.77 detik untuk menyelesaikan 15 epoch, menghasilkan tingkat akurasi latihan sebesar 80.30%, akurasi validasi 81.72%, dan nilai akhir akurasi pengujian berada pada angka **79.83%**.

Di sisi lain, model Transfer Learning berbasis *MobileNetV2* menunjukkan performa yang jauh mengungguli arsitektur dasar. Hanya dalam durasi 5 epoch dengan waktu eksekusi 60.85 detik, akurasi latihan melonjak hingga 96.82

TABLE II  
TABEL KOMPARATIF HASIL EKSPERIMEN MODEL

| Aspek Penilaian    | CNN from Scratch         | Transfer Learning  |
|--------------------|--------------------------|--------------------|
| Akurasi Latihan    | 80.30%                   | 96.82%             |
| Akurasi Validasi   | 81.72%                   | 96.17%             |
| Akurasi Pengujian  | <b>79.83%</b>            | <b>98.67%</b>      |
| Loss Latihan       | 0.4151                   | 0.1043             |
| Loss Validasi      | 0.4006                   | 0.1065             |
| Waktu Latihan      | <b>38.77 detik</b>       | 60.85 detik        |
| Jumlah Parameter   | <b>441,218</b>           | 2,226,434          |
| Risiko Overfitting | Sedang-Rendah            | Sangat Rendah      |
| Kemudahan Impl.    | Rumit (Desain Sendiri)   | Mudah (Pretrained) |
| Kesesuaian Dataset | Kurang (Resolusi Rendah) | Sangat Sesuai      |

## B. Analisis Visualisasi Metrik

Grafik pemantauan latihan pada model dasar memerlukan kurva pembelajaran yang fluktuatif, terutama pada nilai loss validasi. Hal ini mengindikasikan adanya tantangan tersendiri bagi model dalam menggeneralisasi fitur-fitur skala kecil dari gambar berukuran  $32 \times 32$  piksel. Sebaliknya, grafik model *Transfer Learning* mencerminkan kurva pembelajaran yang sangat stabil dan mulus sejak epoch pertama, di mana nilai loss terus menurun secara konsisten seiring bertambahnya iterasi tanpa tanda-tanda *overfitting*.




Fig. 2. Grafik perbandingan akurasi dan loss sepanjang epoch pelatihan untuk kedua model.




Fig. 3. Visualisasi Confusion Matrix pada data pengujian untuk model CNN dari dasar dan Transfer Learning.

Melalui analisis *Confusion Matrix* (Gambar 3), model CNN From Scratch menunjukkan sebaran salah prediksi yang cukup merata antara kelas kucing yang tertebak sebagai anjing maupun sebaliknya. Sementara itu, pada matriks *Transfer Learning*, konsentrasi data terpusat penuh pada diagonal utama (True Positive dan True Negative), dengan jumlah deviasi salah klasifikasi yang sangat minim (hanya beberapa sampel dari total 600 data uji).

Berdasarkan sampel prediksi benar dan salah (Gambar 4 dan Gambar 5), kesalahan pada model dasar dipicu oleh hilangnya informasi spasial akibat pikselasi gambar yang terlalu ekstrem.



Fig. 4. Sampel visualisasi hasil prediksi benar dan salah pada model CNN From Scratch.



Fig. 5. Sampel visualisasi hasil prediksi benar dan salah pada model Transfer Learning MobileNetV2.

Pada model \*Transfer Learning\*, kesalahan klasifikasi umumnya terjadi pada gambar sampel yang memiliki latar belakang kompleks atau posisi tubuh hewan yang tidak standar.

## VI. ANALISIS PENDEKATAN PEMBELAJARAN

### A. Analisis Karakteristik Dataset

Dataset CIFAR-10 ( $32 \times 32$  piksel) pada dasarnya tidak cukup besar dan kaya informasi untuk melatih model CNN dari nol agar mencapai akurasi sangat tinggi (di atas 95

Sebaliknya, kualitas gambar resolusi tinggi pada dataset Kaggle Microsoft Cats vs Dogs menyediakan variasi pencahayaan, pose, dan latar belakang kompleks yang sangat kaya. Keberadaan kompleksitas latar belakang ini justru berhasil disaring dengan sangat baik oleh MobileNetV2 karena lapisan dasarnya telah terlatih membedakan objek utama dari latar belakang pada skala ImageNet.

### B. Analisis Performa Model

Model \*Transfer Learning\* menghasilkan performa terbaik secara mutlak di semua lini pengujian. Nilai akurasi tinggi pada MobileNetV2 (98.67

Strategi pembekuan lapisan dasar terbukti menjaga kestabilan pelatihan secara optimal, berbeda dengan model dari dasar yang rentan mengalami lonjakan nilai loss akibat sensitivitas pembaruan bobot acak terhadap sampel batch kecil.

### C. Panduan Pemilihan Strategi Klasifikasi Citra

Berdasarkan investigasi mendalam dari riset ini, berikut dipaparkan rumusan panduan ilmiah kapan waktu terbaik dalam mengimplementasikan kedua skenario di dunia nyata:

#### 1) Kapan Menggunakan CNN From Scratch:

- **Karakteristik Domain Sangat Unik:** Ketika citra target memiliki distribusi data dan pola visual yang sepenuhnya berbeda dari ImageNet (misalnya: citra satelit radar, citra termal, atau citra mikroskopis tingkat sel).
- **Dataset Skala Masif:** Jika tersedia jutaan data gambar internal perusahaan, melatih model dari awal dapat membentuk ekstraktor fitur baru yang jauh lebih terspesialisasi.
- **Batasan Ukuran Model:** Ketika sistem membutuhkan ukuran file model (bobot eksistensi) yang seminimal mungkin untuk kebutuhan komputasi tepi (\*edge computing\*).

#### 2) Kapan Menggunakan Transfer Learning:

- **Dataset Skala Kecil hingga Menengah:** Solusi mutlak jika sampel data di lapangan berkisar antara ratusan hingga beberapa ribu gambar saja untuk menghindari bahaya laten \*overfitting\*.
- **Keterbatasan Komputasi dan Waktu:** Sangat direkomendasikan jika tenggat waktu pengerjaan proyek sangat sempit (skala hari) dan tidak memiliki infrastruktur superkomputer yang memadai.
- **Kemiripan Objek Tinggi:** Objek klasifikasi termasuk ke dalam ranah objek natural sehari-hari (manusia, hewan, kendaraan, makanan) yang fiturnya sudah matang dipelajari oleh ImageNet.

## VII. STUDI KASUS PENGAMBILAN KEPUTUSAN

### A. Skenario 1: Klasifikasi Citra Medis (300 Gambar)

**Keputusan:** *Transfer Learning (dengan catatan khusus).*

**Argumentasi:** Menggunakan CNN dari dasar dengan 300 gambar dipastikan akan mengalami kegagalan generalisasi dan \*overfitting\* parah. Namun, karena ini citra medis yang polanya berbeda dari ImageNet, strategi terbaik adalah melakukan \*Transfer Learning\* dengan skema \*Fine-Tuning\* pada setengah blok teratas model untuk melatih ulang ekstraktor fitur agar adaptif terhadap guratan citra medis, sembari mempertahankan bobot representasi bentuk dasar pada lapisan bawah.

### B. Skenario 2: 1 Juta Gambar Produk Karakteristik Non-ImageNet

**Keputusan:** *CNN From Scratch atau Fine-Tuning Skala Besar.*

**Argumentasi:** Pendekatan CNN dari dasar menjadi sangat relevan dalam skenario ini. Volume 1 juta gambar memberikan kapasitas sampel yang luar biasa melimpah bagi model untuk mempelajari fitur unik dari produk internal tanpa bergantung pada ImageNet. Melatih dari awal akan membuahkan model klasifikasi produk yang sangat spesifik dan memiliki akurasi jangka panjang yang bernilai tinggi bagi internal perusahaan.

### C. Skenario 3: Prototipe 2 Hari (500 Gambar)

**Keputusan:** *Transfer Learning (Feature Extraction).*

**Argumentasi:** Pilihan paling rasional dan ekonomis adalah menggunakan \*Transfer Learning\* dengan strategi \*Feature Extraction\* (seperti MobileNetV2 atau ResNet). Proses pembekuan layer memastikan pelatihan hanya berjalan di lapisan classifier, yang mana berdasarkan eksperimen kami, mampu selesai dan menghasilkan akurasi tinggi (di atas 90

### D. Skenario 4: Dataset Besar, Domain Spesifik, GPU Memadai

**Keputusan:** *Transfer Learning (Full Fine-Tuning).*

**Argumentasi:** \*Transfer Learning\* tetap sangat diperlukan, namun strateginya diganti menjadi \*Full Fine-Tuning\* (membuka seluruh kunci layer untuk dilatih kembali). Memulai pelatihan dari model yang sudah cerdas (\*pretrained\*) jauh lebih baik daripada memulai dari bobot acak (\*random initialization\*). Pengetahuan dasar dari ImageNet akan bertindak sebagai jangkar regularisasi, mempercepat waktu konvergensi, dan menghasilkan performa yang lebih stabil dan superior untuk domain spesifik tersebut.

## VIII. KESIMPULAN DAN REFLEKSI PRIBADI

### A. Kesimpulan

Penelitian komparatif ini berhasil memberikan bukti empiris yang kuat mengenai keunggulan metode \*Transfer Learning\* (MobileNetV2) dibandingkan pembangunan CNN dari dasar (\*from scratch\*). Dengan volume data yang lebih sedikit dan waktu ekstraksi yang singkat, \*Transfer Learning\* mampu menembus akurasi sebesar 98.67

## B. Refleksi Pribadi

- 1) **Tantangan Terbesar:** Menyelaraskan ukuran input tensor dan memisahkan alur ekstraksi indeks sub-kelas CIFAR-10 secara murni, serta mengonfigurasinya ke dalam struktur loader PyTorch tanpa merusak konsistensi data.
- 2) **Bagian Paling Sulit:** Membangun CNN dari dasar. Menentukan jumlah lapisan filternya, ukuran *padding*, hingga menjaga nilai dropout agar model tidak mengalami penurunan performa drastis (*\*drop accuracy\**) pada saat validasi memerlukan proses *trial-and-error* yang cukup intensif.
- 3) **Perbedaan Paling Terasa:** Kecepatan konvergensi. Pada model *\*from scratch\**, akurasi merangkak sangat lambat dari 50
- 4) **Pendekatan untuk Kasus Nyata:** Saya akan memilih pendekatan *\*Transfer Learning\**. Dalam industri, efisiensi waktu pengerjaan, jaminan akurasi tinggi, dan minimalisir kebutuhan resource GPU merupakan parameter kesuksesan implementasi komersial.
- 5) **Hal Baru yang Dipelajari:** Pengambilan keputusan dalam deep learning tidak melulu soal mencari akurasi tertinggi, melainkan trade-off yang bijak antara volume ketersediaan data, kemiripan domain objek, tenggat waktu pengerjaan, dan kapasitas infrastruktur komputasi yang dimiliki.

## REFERENSI

- [1] V. R. Prasetyo, "Deep-Learning-Course Repository," GitHub, 2026. [Online]. Available: <https://github.com/virgantara/Deep-Learning-Course>.
- A. Paszke, et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in Advances in Neural Information Processing Systems 32, 2019, pp. 8024-8035.
- Microsoft, "Microsoft CatsVSDogs Dataset," Kaggle, 2023. [Online]. Available: <https://www.kaggle.com/datasets/shaunthesheep/microsoft-catsvsdogs-dataset>.